Bagian A: Analisis Konseptual

1. **Efek Regularisasi pada Batch Normalization (Slide 6–8)**

   Slide 8 menyebutkan bahwa Batch Normalization "acts like mild regularization" dan "often eliminates the need for Dropout".

   ▼ Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.

   Mekanisme Statistik Mini-Batch:

   - Batch Normalization (BatchNorm) menghitung rata-rata (μ_B) dan varians (σ_B^2) secara spesifik pada setiap mini-batch saat fase training (Slide 6–8). Fluktuasi stokastik antar mini-batch ini menambahkan sedikit noise pada estimasi aktivasi tiap neuron. Noise stokastik ini bertindak sebagai regularisasi ringan (mild regularization) dengan mencegah jaringan bergantung secara berlebihan pada kombinasi bobot neuron tertentu, mirip dengan peran peredam overfitting pada Dropout (Slide 8).

   ▼ Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.

   Skenario Kegagalan / Instabilitas:

   - Asumsi bahwa BatchNorm dapat menggantikan Dropout tidak berlaku ketika ukuran mini-batch sangat kecil (misalnya $N < 8$), karena estimasi statistik mini-batch menjadi sangat bias dan fluktuatif, sehingga memicu instabilitas konvergensi pelatihan. Selain itu, penggabungan BatchNorm dengan Dropout pada arsitektur CNN yang sama sering kali memicu fenomena variance shift akibat ketidakcocokan statistik aktivasi antara mode train dan eval.

---

2. **Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)**

   Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam

minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?

▼ Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).

Penyebab Degradation Problem:

- Pada plain CNN tanpa skip connection (Slide 10), penambahan kedalaman lapisan memperpanjang rantai transformasi non-linear yang kompleks. Walaupun secara teoritis model dalam mampu merepresentasikan fungsi identitas ($H(x) = x$), fungsi aktivasi non-linear secara empiris sangat sulit mempelajari pemetaan identitas murni dari nol. Hal ini mengakibatkan terjadinya degradation problem, di mana akurasi pelatihan justru menurun seiring bertambahnya kedalaman.

▼ Hubungkan mekanisme tersebut dengan mitigasi fenomena vanishing gradient yang telah dibahas pada Sesi 02.

Formulasi Gradien & Mitigasi Vanishing Gradient:

- Residual Connection merumuskan ulang target pemetaan menjadi $F(x) = H(x) - x$, sehingga output lapisan menjadi $y = F(x) + x$ (Slide 11). Saat propagasi balik (backpropagation), turunan gradien dirumuskan sebagai:

$$\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial \mathcal{L}}{\partial y} \cdot \left(\frac{\partial F(x)}{\partial x} + 1 \right)$$

  Adanya suku konstan $+1$ menjamin aliran gradien dapat melintasi backbone secara langsung tanpa tereduksi oleh perkalian matriks bobot yang bernilai kurang dari 1, sehingga secara efektif memitigasi fenomena vanishing gradient (Sesi 02 & Slide 11).

---

3. **Feature Extraction vs. Fine-Tuning (Slide 14–16)**

   Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan Fine Tuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:

▼ Jumlah parameter yang diperbarui (trainable parameters).

- Trainable Parameters: Feature Extraction hanya mengoptimalkan classifier head baru (misal layer fc ResNet-18 ≈ 5.130 parameter), sedangkan Fine-Tuning mengoptimalkan sebagian besar atau seluruh parameter jaringan (hingga jutaan parameter).

▼ Kebutuhan volume data latih.

- Volume Data: Feature Extraction memerlukan volume data minimal karena backbone tidak diperbarui, sementara Fine-Tuning membutuhkan sampel data lebih besar untuk mencegah overfitting.

▼ Beban komputasi dan memori per epoch.

- Beban Komputasi: Feature Extraction sangat hemat memori GPU dan waktu pelatihan per epoch, sedangkan Fine-Tuning mengonsumsi sumber daya komputasi yang tinggi.

▼ Risiko rusaknya fitur representasi bawaan (destructive gradient updates). Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.

- Risiko Destructive Gradient Updates: Fine-Tuning berisiko tinggi merusak representasi visual pretrained jika learning rate terlalu besar, sedangkan Feature Extraction terbebas dari risiko tersebut.
- **Sintesis Kriteria**:
  Pilih Feature Extraction jika dataset sangat terbatas dan memiliki domain visual mirip ImageNet. Gunakan Fine-Tuning jika ketersediaan data mencukupi atau domain target memiliki karakteristik visual yang sangat berbeda dari ImageNet.

---

4. **Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)**

▼ Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.

Pertimbangan Metodologis:

- Data Augmentation hanya diaktifkan pada train set untuk menambah keanekaragaman variasi sampel secara sintetis (Slide 20–21). Hal ini

memaksa model mempelajari representasi fitur yang invariant terhadap perubahan spasial dan warna, sehingga generalization gap berkurang. Sebaliknya, validation/test set wajib dibebaskan dari augmentasi acak agar pengukuran metrik performa bersifat deterministik, objektif, dan mencerminkan distribusi data dunia nyata tanpa adanya distorsi buatan.

▼ Berikan satu contoh teknik transformasi citra yang tidak layak digunakan untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label

Contoh Transformasi Tidak Layak (Pet Breeds):

- Penerapan Vertical Flip atau Extreme Rotation (180°) tidak layak untuk klasifikasi ras hewan peliharaan (Slide 21). Hewan seperti kucing atau anjing secara alami memiliki orientasi tubuh vertikal (kepala di atas). Pembalikan vertikal merusak semantic label invariance karena menciptakan objek yang secara taksonomi dan fisiologis tidak realistis di alam liar, sehingga membingungkan representasi spasial model.

---

5. **Mitigasi Catastrophic Forgetting (Slide 28–29)**

   Slide 28 mengingatkan potensi terjadinya catastrophic forgetting apabila proses adaptasi model berlangsung terlalu agresif.

   ▼ Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.

   Mekanisme Catastrophic Forgetting:

   - Fenomena ini terjadi saat model pretrained di-adaptasi secara terlalu agresif dengan learning rate tinggi pada data baru (Slide 28). Pembaruan bobot (gradient update) yang drastis akan langsung mengganti dan menghapus representasi fitur visual generik (seperti pendeteksi tepi, tekstur, dan bentuk) yang sebelumnya telah dipelajari dari ImageNet.

▼ Jelaskan dua strategi mitigasi konkret (misalnya differential learning rate, gradual unfreezing, atau linear warmup) beserta alasan teoritis mengapa strategi tersebut efektif.

- **Differential Learning Rate**: Menerapkan learning rate bertingkat, yaitu nilai sangat kecil (misal 10^{-4}) pada lapisan backbone bawah agar bobot tidak rusak, serta learning rate lebih besar (misal 10^{-3}) pada classifier head untuk mempercepat adaptasi target.
- **Gradual Unfreezing / Warmup**: Pelatihan diawali dengan membekukan seluruh backbone hingga lapisan head stabil, kemudian pembekuan dibuka secara bertahap dari lapisan atas ke bawah. Strategi ini secara teoritis mencegah destructive gradient updates pada fitur-fitur awal jaringan.