Laporan Analisis GSLC Deep Learning Sesi 05
Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas (Oxford-IIIT Pet, 10 Kelas)

Nama: Axel Sanjiro Yang | NIM: 2802472400 | Mata Kuliah: Deep Learning | Repositori: [tautan GitHub]

1. Ringkasan dan Konfigurasi Eksperimen

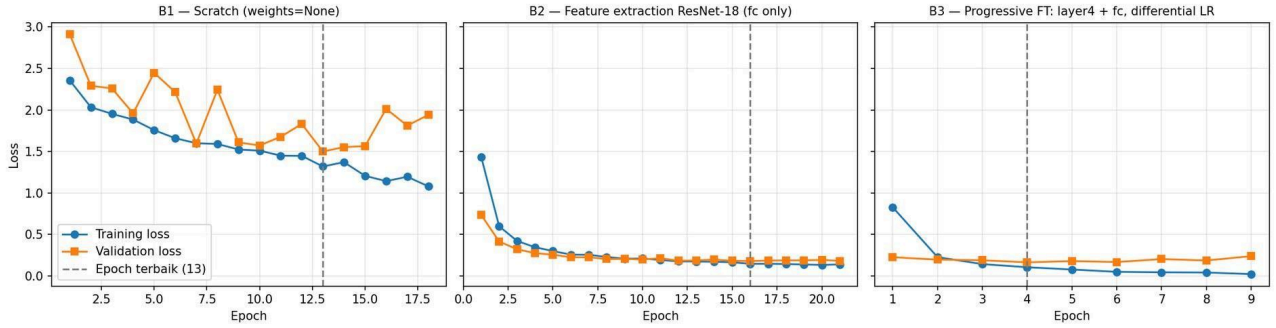
Laporan ini membandingkan lima kondisi pelatihan (B1-B5) untuk menjawab pertanyaan pada Slide 15-16: kapan backbone cukup dibekukan (feature extraction) dan kapan fine-tuning diperlukan. Seluruh angka bersumber dari berkas experiment_log.csv, history_log.csv, dan failure_analysis.csv yang dilampirkan bersama laporan ini.

- **Dataset:** Oxford-IIIT Pet, 10 kelas pertama (5 kucing: Abyssinian, Bengal, Birman, Bombay, British Shorthair; 5 anjing: American Bulldog, American Pit Bull Terrier, Basset Hound, Beagle, Boxer). Total 1.981 citra, stratified split 70/15/15 menjadi 1.386 train / 297 validation / 298 **test**. Indeks antar-split diverifikasi saling lepas dengan assert (tanpa data leakage).
- **Protokol seragam:** ResNet-18 (ImageNet1K_V1), input 224x224 dengan normalisasi ImageNet, batch 32, AdamW (weight decay 1e-2), CrossEntropyLoss, maksimum 30 epoch, early stopping pada validation loss (patience 5) dan bobot epoch terbaik dipulihkan sebelum evaluasi. Seed 42 (Python, NumPy, PyTorch, cuDNN deterministik). GPU Tesla T4 (Google Colab).
- **Detail implementasi:** Augmentasi (RandomResizedCrop 0,8-1,0; horizontal flip; rotasi 15 derajat; ColorJitter brightness/contrast 0,2) hanya pada train set; validation/test memakai transformasi deterministik. Layer BatchNorm pada bagian yang dibekukan dipaksa mode eval() agar statistik running ImageNet tidak berubah.
- **Metrik:** Train_Acc_Clean = akurasi train tanpa augmentasi pada bobot terbaik; Gen_Gap = Train_Acc_Clean dikurangi Val_Acc; durasi mencakup epoch patience setelah titik terbaik.

C1. Tabel Konsolidasi dan Kurva Pembelajaran

Kode	Strategi	Trainable params	Learning rate	Epoch konv. / total	Durasi (s)	Val Acc	Test Acc	Test Macro -F1
B1	ResNet-18 from scratch	11.181.642	semua 1e-3	13 / 18	144.3	0.4815	0.5168	0.4736
B2	ResNet-18 feature extraction (fc saja)	5.130	fc 1e-3	16 / 21	137.1	0.9394	0.9329	0.9333
B3	**Progressive FT: layer4 + fc, differential LR**	**8.398.858**	**layer4 1e-4; fc 1e-3**	**4 / 9**	**58.5**	**0.9394**	**0.9396**	**0.9399**
B4 (B3 tanpa aug.)	B3, tanpa augmentasi	8.398.858	layer4 1e-4; fc 1e-3	4 / 9	34.7	0.9495	0.9396	0.9399
B4 (B3 dengan aug.)	B3, dengan augmentasi	8.398.858	layer4 1e-4; fc 1e-3	4 / 9	60.9	0.9394	0.9396	0.9399
B5	**EfficientNet-B0 feature extraction**	**12.810**	**classifier 1e-3**	**21 / 26**	**180.1**	**0.9596**	**0.9530**	**0.9531**

Tabel 1. Konsolidasi hasil (seed 42). Total parameter ResNet-18: 11.181.642; EfficientNet-B0: 4.020.358. Note: B3 (terbaik di ResNet-18) dan B5 (terbaik keseluruhan).



Gambar 1. Training loss vs. validation loss untuk B1, B2, B3.

C2. Pembahasan Analisis Komparatif

C2.1 Disparitas B1 terhadap B2 dan B3

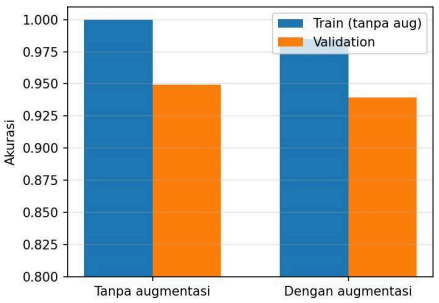
B1 hanya mencapai Test Macro-F1 **0,4736** (Test Acc 0,5168), sedangkan B2 dan B3 mencapai **0,9333** dan **0,9399**, selisih sekitar 46 poin. Train accuracy bersih B1 hanya 0,5397, jadi masalahnya adalah **underfitting dan optimasi yang tidak stabil**, bukan memorisasi: validation loss berosilasi (1,50-2,45 setelah epoch 3) karena 11,18 juta parameter (sekitar 8.000 per citra) harus belajar fitur dasar dari 1.386 citra. B2 sudah mencapai validation accuracy 0,8687 pada epoch pertama karena fitur ImageNet dapat langsung dipakai ulang (Slide 15-16); ImageNet juga memuat banyak ras anjing/kucing sehingga domain ini sangat menguntungkan. ResNet-18 sudah memiliki residual connection dan BatchNorm (Slide 10-12), jadi degradasi kedalaman bukan penyebabnya; kendalanya volume data. B1 mungkin belum sepenuhnya konvergen (early stopping dipicu validation loss yang bising), tetapi validation accuracy epoch 14-18 tidak naik (maks. 0,5118) sehingga kecil kemungkinan menyamai transfer learning.

C2.2 Trade-off performa vs. stabilitas: feature extraction vs. fine-tuning bertahap

B3 unggul tipis atas B2 (Test Acc 0,9396 vs 0,9329; Macro-F1 0,9399 vs 0,9333), yaitu 2 dari 298 citra, masih dalam interval kepercayaan 95% sekitar +/-2,7 poin sehingga **tidak dapat dibedakan dari noise**. Perbedaan jelas ada pada perilaku pelatihan. B2 (5.130 parameter) konvergen lambat (epoch 16) namun mulus, dengan train dan validation loss berdekatan (0,146 vs 0,179). B3 (8.398.858 parameter, 75% bobot) konvergen di epoch 4 (58,5 vs 137,1 detik) tetapi cepat overfit: validation loss naik dari 0,1635 ke 0,2386 pada epoch 9 sementara training loss turun ke 0,0229. Karena itu early stopping dan LR diferensial (layer4 10x lebih kecil dari fc) menjadi pengaman terhadap pembaruan gradien yang merusak fitur bawaan (Slide 28). Forgetting tidak diukur langsung, sehingga kesimpulannya hanya bahwa B3 lebih sensitif terhadap durasi pelatihan.

C2.3 Peran augmentasi (B4) dalam meredam overfitting

Pada B3, tanpa augmentasi: train accuracy 1,0000, Val Acc 0,9495, Gen_Gap **0,0505**; dengan augmentasi: 0,9848, 0,9394, **0,0455**. Celah menyempit hanya 0,5 poin karena train accuracy turun, bukan validation accuracy naik; Val Acc dengan augmentasi justru 1,01 poin lebih rendah (3 dari 297 citra), sedangkan Test Acc (0,9396) dan Macro-F1 (0,9399) identik. Selisih loss train-validation pada epoch terbaik lebih terlihat (0,0275 vs 0,1632 tanpa augmentasi; 0,1048 vs 0,1635 dengan augmentasi), walau tidak sepenuhnya sebanding karena train loss dihitung pada data terdistorsi. Jadi augmentasi **melambatkan memorisasi** (Slide 20) tetapi **belum terbukti meningkatkan generalisasi**; kemungkinan karena fitur pretrained sudah kokoh, early stopping berhenti di epoch 4, dan augmentasinya ringan. B3 dan B4_Aug (konfigurasi identik) menghasilkan metrik yang sama persis, sehingga reproduksibilitas terkonfirmasi.



Gambar 2. Train accuracy (tanpa augmentasi saat evaluasi) vs. validation accuracy pada B4.

C3. Failure Analysis

Model terbaik berdasarkan Test Macro-F1 adalah B5 (14 salah dari 298 citra, akurasi 95,3%). Delapan sampel di bawah ini adalah kesalahan dengan **confidence tertinggi** (opsi highest_conf pada notebook), sehingga sengaja bias ke kasus yang paling overconfident. Kolom p(true) adalah probabilitas yang diberikan model kepada kelas yang benar.



Gambar 3. Delapan misklasifikasi dengan confidence tertinggi pada test set (model B5).

#	Berkas	Label aktual	Prediksi	Conf.	P (true)	Hipotesis penyebab
1	american_bulldog_54.jpg	American Bulldog	Boxer	0.981	0.017	Corak brindle, moncong pendek, dan 'masker' wajah gelap sangat mirip Boxer; ambiguitas visual antar ras sejenis (bully-type).
2	beagle_189.jpg	Beagle	American Bulldog	0.957	0.019	Sudut pengambilan dari atas dan objek kecil di tengah latar kerikil bertekstur padat. Warna putih-coklat dan tubuh pendek menyerupai American Bulldog.
3	Bengal_134.jpg	Bengal	Abyssinian	0.947	0.053	Close-up dengan bulu oranye polos tanpa pola marbling yang terlihat kesan ticked-coat mirip Abyssinian.
4	Bombay_160.jpg	Bombay	Abyssinian	0.941	0.014	Kucing hitam pada latar ungu jenuh, tekstur bulu hilang dan pose melengkung dari atas.
5	american_pit_bull_terrier_27.jpg	American Pit Bull Terrier	American Bulldog	0.921	0.057	Citra hanya memuat kepala sehingga bentuk tubuh berotot yang menjadi pembeda Pitbull tidak terlihat.

6	Abyssinian_215.jpg	Abyssinian	Bengal	0.783	0.170	Pose ekstrem dengan oklusi kotak Pepsi serta wajah sebagian tertutup bulu putih di perut dominan, pola ticked tidak terlihat. Confidence relatif rendah (0,78) dan p(true) 0,17 menunjukkan model ragu.
7	boxer_18.jpg	Boxer	American Bulldog	0.755	0.211	Boxer berwarna putih dan berukuran kecil di frame sambil bergerak, latar polos. Warna putih lebih khas American Bulldog, fitur wajah tidak jelas.
8	american_bulldog_102.jpg	American Bulldog	Boxer	0.649	0.030	Anjing fawn dengan dada putih, duduk, moncong pendek mirip Boxer fawn. Confidence terendah (0,65) dan p(true) hanya 0,03, indikasi ambiguitas ras.

Tabel 2. Rincian failure analysis.

Pola umum empat dari delapan kasus berada pada segitiga ras bully-type (American Bulldog, American Pit Bull Terrier, Boxer), dan tiga lainnya pada kucing berbulu pendek (Abyssinian, Bengal, Bombay). Confusion matrix (Gambar 4) konsisten: Bengal ke Abyssinian 10% (sekitar 3 dari 30 citra), American Bulldog ke Boxer 7%. Lima dari delapan kesalahan memiliki confidence 0,92 atau lebih sehingga model overconfident; pada penerapan nyata, probabilitas softmax tidak boleh dipakai langsung sebagai ukuran ketidakpastian tanpa kalibrasi.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

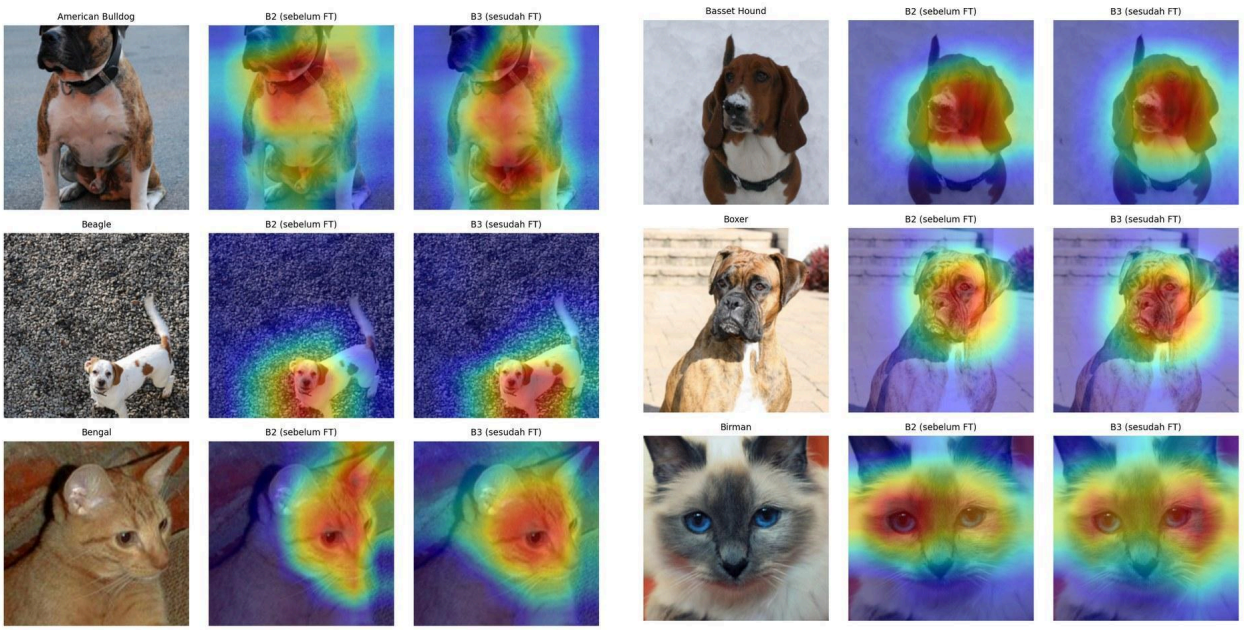
Rekomendasi

- **feature extraction (B2/B5):** Test Acc 93-95% dengan hanya 5.130-12.810 parameter terlatih, kurva mulus, dan risiko merusak fitur bawaan rendah (Slide 29).
- **Naik ke fine-tuning layer4 + differential LR (B3)** bila domain berbeda dari ImageNet atau target belum tercapai. Wajib disertai early stopping (optimum di epoch 4, setelahnya overfit); keuntungan B3 atas B2 (sekitar 0,7 poin) belum signifikan secara statistik.
- **Jika memori atau ukuran model dibatasi,** EfficientNet-B0 feature extraction memberi F1 terbaik dengan 36% parameter ResNet-18, namun tidak otomatis lebih cepat; ukur latensi pada perangkat target.
- **Hindari pelatihan dari nol** pada sekitar 140 citra per kelas. Augmentasi layak menjadi default berbiaya rendah, tetapi manfaatnya belum terbukti pada studi ini.

Batasan Studi

- **Single seed (42):** Tanpa estimasi varians; selisih B2, B3, B5 (278, 280, 284 benar dari 298) berada dalam interval kepercayaan 95% (+/-2,4 sampai 2,8 poin) sehingga tidak terpisah secara statistik.
- **Cakupan terbatas:** 10 dari 37 kelas dan test set 298 citra; ImageNet memuat ras serupa sehingga transfer lebih mudah dibanding domain asing.
- **Seleksi model memakai test set:** B5 dipilih lewat Test Macro-F1 sehingga ada bias optimistik; sebaiknya memakai validation set.
- **Tidak ada tuning hyperparameter:** ((LR, scheduler, weight decay); B1 tidak dioptimalkan khusus, dan B5 memakai konfigurasi feature extraction, bukan B3. Durasi mencakup epoch patience dan pipeline data di Colab sehingga bersifat indikatif.
- **B4_Aug adalah pengulangan B3:** bukan run independen; kesamaan metrik test B3 dan B4_NoAug (0,9396 / 0,9399) belum diperiksa per sampel.

C5. Eksplorasi Tambahan: Grad-CAM pada layer4 (Sebelum vs. Sesudah Fine-Tuning)



Gambar 5. Grad-CAM layer4 untuk kelas sebenarnya: B2 (sebelum fine-tuning) vs. B3 (sesudah).

Secara umum peta aktivasi bergeser sangat sedikit: pada Beagle, Basset Hound, dan Boxer, B2 dan B3 sama-sama terpusat pada wajah dan kepala, yang menunjukkan bahwa representasi pretrained tetap dipertahankan setelah fine-tuning (Slide 29). Pergeseran yang terlihat: pada Bengal, aktivasi B3 lebih terkonsentrasi pada mata dan pipi dibanding B2 yang juga mencakup telinga dan hidung; pada Birman, B3 menyebar lebih simetris ke kedua mata; pada American Bulldog, B3 menambah area aktivasi di bagian bawah tubuh yang tampaknya bukan cue diskriminatif. Pergeseran kecil ini wajar karena hanya satu blok yang dibuka, learning rate layer4 rendah (1e-4), dan model berhenti pada epoch 4. Interpretasi ini kualitatif (6 sampel, resolusi peta 7x7 yang di-upsample) dan tidak dapat dijadikan bukti kuantitatif.

Referensi

[1] Parkhi, O. M., Vedaldi, A., Zisserman, A., Jawahar, C. V. (2012). Cats and Dogs. IEEE CVPR.

[2] He, K., Zhang, X., Ren, S., Sun, J. (2016). Deep Residual Learning for Image Recognition. IEEE CVPR.

[3] Tan, M., Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML.

[4] Selvaraju, R. R. et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. IEEE ICCV.

[5] Loshchilov, I., Hutter, F. (2019). Decoupled Weight Decay Regularization (AdamW). ICLR.

[6] Sesi 05 - Advanced CNNs and Transfer Learning (bahan tayang kuliah), Slide 10-12, 15-16, 20, 24, 28-29.

Lampiran: Pernyataan Penggunaan AI (AI Disclosure Statement)

- **Alat/model:** Claude
- **Ruang lingkup bantuan:** membantu menyusun kerangka dan draf bahasa laporan dari berkas log CSV dan grafik hasil eksperimen dan membantu debugging code notebook. Eksekusi eksperimen dilakukan sendiri di Google Colab.
- **Verifikasi mandiri:** seluruh angka pada laporan dicocokkan ulang dengan experiment_log.csv dan history_log.csv; hipotesis failure analysis diperiksa terhadap gambar pada failure_analysis.png; interpretasi dan kesimpulan ditinjau dan diedit ulang secara mandiri.